

Tema1 IA

Manea Lidia-Elena - 341C4

30. November 2024

0.1 Flow-ul programului

Am început prin a citi datele și a le introduce în liste. Atât pentru setul de date cu fructe, cât și pentru cel mnist, am citit imaginile, le-am scalat și le-am introdus în liste. Am ales algoritmi de extragere de atribute pe baza raționamentului de mai jos. Am combinat subclasele de fructe în clase mai mari, iar apoi am făcut graficele cu numărul de imagini ale claselor atât pe train, cât și pe test, respectiv graficele distribuției PCA. Am aplicat PCA cu 2, respectiv 3 componente pe ambele seturi de date și de asemenea am aplicat trasarea contururilor pentru a vizualiza rezultatele. După toți acești pași de vizualizare, am început să scriu codul pentru preprocesare: am aplicat PCA cu 27 de componente pe imagini, rezultatele stocându-le în vectori. Totodată, am aplicat hu moments pe imagini, iar apoi rezultatele de la PCA și hu moments le-am concatenat pentru a obține vectorii finali. După obținerea acestor rezultate, am aplicat algoritmi cu diversi hiperparametri pentru a extrage cele mai bune opțiuni.

0.2 Extragerea de atribute (Feature Extraction)

Pentru extragerea atributelor, am luat în considerare următoarele:

Pentru imagini referitoare la articole vestimentare, hainele sunt recunoscute în funcție de conturul acestora, adică pantalonii diferă prin rochii în primul rând prin forma acestora. Acest lucru se poate aplica și la fructe: o banană diferă de ananas prin forma acestuia. De aceea, am ales să utilizez hu moments pentru stabilirea conturului imaginilor. De asemenea, am ales să utilizez PCA pentru ambele seturi de date pentru a extrage cele mai importante și distincte features din imagini.

0.3 Vizualizarea echilibrului între clase

În setul de date cu fructe, există un dezechilibru între clase (de exemplu pentru clasa Cabbage White 1 sunt sub 200 de imagini, în timp ce pentru Pear Stone 1 sunt aproape 800 de imagini). Există această situație atât pentru train, cât și pentru test la setul de imagini cu fructe. După ce am combinat subclasele, am constatat că încă există un dezechilibru, diferând foarte mult prin numărul imaginilor. Pentru setul de date fashion mnist, clasele sunt perfect echilibrate, existând același număr de imagini pentru fiecare clasă (cate 6000 de imagini pentru fiecare clasă train, cate 1000 de imagini pentru fiecare clasă test).




Abbildung 1: Folder train




Abbildung 2: Folder train




Abbildung 3: Folder train




Abbildung 4: Folder train

0.4 Vizualizarea cantitativă a efectului de extragere a atributelor

Deoarece am aplicat PCA peste setul de date, am facut graficul de varianta cumulativa al componentelor PCA pe ambele seturi de date. Asadar, pentru ambele seturi de date, dupa ce am aplicat PCA pe 50 componente, observ ca varianta componentelor scade treptat, majoritatea fiind redundante. De aceea, am ales sa iau primele 27 de componente in ambele cazuri. 27 este un numar care acopera componente care sunt foarte utile, dar si din componentele redundante.

0.5 Vizualizarea calitativa a efectului de extragere a atributelor

Deoarece metoda mea de extragere a atributelor se bazeaza pe PCA si pe Hu moments, am aplicat PCA cu 27 componente pe diverse imagini si am aplicat si trasarea conturului pe un set de imagini. Imaginile rezultate, alaturi de labelurile lor, sunt prezente mai jos.

Se observa ca la PCA, 27 componente pe setul de ambele seturi de date sunt relativ suficiente pentru a distinge forma si culoarea obiectelor. De asemenea, conturul este foarte bine trasat, descoperind si particularitati ale fructelor (de exemplu contururi pe suprafata acestora).




Abbildung 5: Folder train

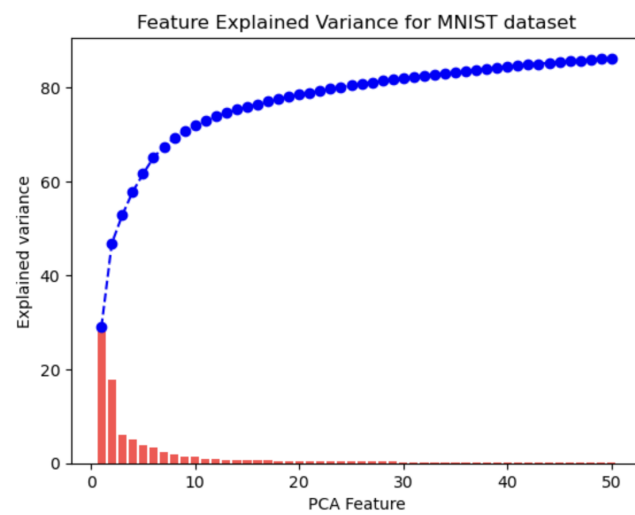


Abbildung 6: Folder train




Abbildung 7: Ankle boots pca




Abbildung 8: Bag pca




Abbildung 9: Coat pca




Abbildung 10: Dress pca




Abbildung 11: Pullover pca




Abbildung 12: Sandal pca




Abbildung 13: Shirt pca




Abbildung 14: Sneaker pca




Abbildung 15: Apple pca




Abbildung 16: Banana pca




Abbildung 17: Cherry pca




Abbildung 18: Grape pca




Abbildung 19: Peach pca




Abbildung 20: Pear pca




Abbildung 21: Pepper pca




Abbildung 22: Plum pca




Abbildung 23: Potato pca




Abbildung 24: Tomato pca




Abbildung 25: Apple contour




Abbildung 26: Banana contour



Abbildung 27: Cherry contour




Abbildung 28: Grape contour




Abbildung 29: Peach contour




Abbildung 30: Pear contour



Abbildung 31: Pepper contour



Abbildung 32: Plum contour



Abbildung 33: Tomato contour

0.6 Rezultate algoritmi pentru setul de date Fruits

Pentru setul de date Fruits am aplicat cei 4 algoritmi cu diversi hiperparametri. Pentru logistic regression am luat: $C = [0.1, 1, 10]$, $\text{max iter} = [100, 1000, 10000]$, $\text{multi class} = [\text{auto}, \text{ovr}, \text{multinomial}]$, $\text{solver} = [\text{newton-cg}, \text{lbfgs}, \text{sag}, \text{saga}]$. Pe masura ce rata de invatare crestea, crestea si acuratetea. Intr-un final am obtinut rezultate foarte bune pentru $C=0.1$, $\text{max iter}=1000$, $\text{multi class}=\text{auto}$, $\text{solver}=\text{newton-cg}$. Pe setul de train am obtinut o acuratete de 77.53, iar pe setul de test am obtinut o acuratete de 65.1. Pentru Random Forest am luat $\text{number trees} = [5, 10, 50, 100, 200]$, $\text{max depth} = [5, 10, 50, 100, 500, \text{None}]$, $\text{max features} = [0.2, 0.5, 0.8, 1]$. Am obtinut scoruri diferite radical, spre deosebire de logistic regression, care parea dependent mai mult de rata de invatare. Random forest performeaza mai bine pentru max samples care sunt diferite de 1, adica mai mici decat 1. Acuratetea pe train este suspect de mare, iar pe test este buna si ea. Pentru 99 acuratete pe train am obtinut 94 pe test, cu hiperparametri $n\text{ estimators}=200$, $\text{max depth}=50$, $\text{max samples}=0.8$. Pentru svm, am luat urmatoarele: $C = [0.01, 0.1, 1, 10]$, $\text{kernel} = [\text{linear}, \text{poly}, \text{rbf}, \text{sigmoid}]$. Se observa ca modelul are acuratete mare pe train in general pentru kernelul liniar, inasa pe masura ce creste rata de invatare, creste si acuratetea pe restul kernelelor. Cea mai buna acuratete am obtinut-o pentru $c=10$ si $\text{kernel}=\text{rbf}$. Pe train am 99, iar pe test am 94. Pentru xgboost, am luat urmatorii hiperparametri: $N = [10, 50, 100, 150, 200]$, $\text{max depth} = [3, 5, 10, 20]$, $\text{lr} = [0.1, 0.01, 0.001]$. Se observa ca pe masura ce numarul de arbori creste, creste si acuratetea, iar pe masura ce creste si adancimea maxima, creste si acuratetea (tendinta de overfit). Pentru 200 de arbori, adancimea 5, learning

rate 0.1, am obtinut 99 acuratete pe train si 85 pe test.

0.7 Rezultate algoritmi pentru setul de date MNIST

Am aplicat algoritmii pe setul de date MNIST, cu aceiasi hiperparametri si aceleasi valori ale acestora. Pentru Random Forest, cele mai bune valori le-am obtinut pentru n estimators=200, max depth=None, max samples=0.8; atat pe test, cat si pe train am obtinut acuratete de 85. Pentru xgboost, am obtinut o acuratete pe train si pe test de 87, cu hiperparametri max depth=20, learning rate=0.1, numar arbori=200. Pentru logistic regression, am obtinut acuratete de 81 pentru train si test, pentru hiperparametri $C=10$, max iter=1000, multi class=auto, solver = newton-cg. Pentru svm, cu hiperparametri $C=10$ si kernel=rbf am obtinut acuratete de 88 atat pe train cat si pe test.

0.8 Prediction, Recall, F1-score Fruits

Pentru logistic regression:

precision recall f1-score support

Apple	0.5159	0.6808	0.5870	2525
Apricot	0.7244	0.5610	0.6323	164
Avocado	0.6684	0.8414	0.7450	309
Banana	0.7104	0.5930	0.6464	484
Beetroot	0.5781	0.2467	0.3458	150
Blueberry	0.8455	0.6753	0.7509	154
Cabbage	1.0000	0.9574	0.9783	47
Cactus	0.5122	0.5060	0.5091	166
Cantaloupe	0.9752	0.9573	0.9662	328
Carambula	0.4242	0.2530	0.3170	166
Carrot	0.8772	1.0000	0.9346	50
Cauliflower	0.5964	0.7009	0.6444	234
Cherry	0.5595	0.5366	0.5478	1148
Chestnut	0.5631	0.3791	0.4531	153
Clementine	0.9822	1.0000	0.9910	166
Cocos	0.6893	0.7349	0.7114	166
Corn	0.5874	0.4309	0.4972	304
Cucumber	0.6725	0.6451	0.6585	417
Dates	0.9362	0.7952	0.8599	166

Eggplant 0.6108 0.4322 0.5062 236
Fig 0.8987 0.6068 0.7245 234
Ginger 0.2941 0.0505 0.0862 99
Granadilla 0.6538 0.6145 0.6335 166
Grape 0.7121 0.8290 0.7661 1146
Grapefruit 0.9617 0.9879 0.9746 330
Guava 0.9000 0.8675 0.8834 166
Hazelnut 0.8063 0.8217 0.8139 157
Huckleberry 1.0000 0.9699 0.9847 166
Kaki 0.7970 0.9458 0.8650 166
Kiwi 0.6610 0.5000 0.5693 156
Kohlrabi 0.7500 0.4204 0.5388 157
Kumquats 0.8768 0.7289 0.7961 166
Lemon 0.7827 0.7424 0.7621 330
Limes 0.8912 0.7892 0.8371 166
Lychee 0.9595 1.0000 0.9794 166
Mandarine 0.4800 0.5060 0.4927 166
Mango 0.5709 0.5487 0.5596 308
Mangostan 0.7595 0.5882 0.6630 102
Maracuja 0.9487 0.8916 0.9193 166
Melon 0.7461 0.7764 0.7610 246
Mulberry 0.9154 0.7256 0.8095 164
Nectarine 0.2481 0.0988 0.1413 324
Nut 0.5581 0.3763 0.4495 396
Onion 0.5392 0.6408 0.5856 451
Orange 0.8989 1.0000 0.9467 160
Papaya 0.9324 0.8415 0.8846 164
Passion 0.9938 0.9699 0.9817 166
Peach 0.4423 0.3206 0.3717 574
Pear 0.4186 0.4191 0.4188 1761
Pepino 0.6162 0.6867 0.6496 166
Pepper 0.6008 0.5521 0.5754 826
Physalis 0.7409 0.7409 0.7409 328
Pineapple 0.7586 0.8693 0.8102 329
Pitahaya 0.7296 0.8614 0.7901 166
Plum 0.7426 0.7538 0.7481 597
Pomegranate 0.4926 0.4085 0.4467 164

Pomelo 0.9329 1.0000 0.9653 153
 Potato 0.4541 0.3295 0.3819 601
 Quince 0.9294 0.9518 0.9405 166
 Rambutan 0.7887 0.9329 0.8547 164
 Raspberry 1.0000 0.9639 0.9816 166
 Redcurrant 1.0000 0.7134 0.8327 164
 Salak 0.5249 0.8457 0.6478 162
 Strawberry 0.5765 0.3951 0.4689 410
 Tamarillo 0.6946 1.0000 0.8198 166
 Tangelo 0.8508 0.9277 0.8876 166
 Tomato 0.6139 0.6930 0.6511 1707
 Walnut 0.7367 1.0000 0.8484 249
 Watermelon 0.8931 0.7452 0.8125 157
 Zucchini 0.7960 1.0000 0.8864 160

accuracy 0.6505 23619
 macro avg 0.7271 0.6982 0.7032 23619
 weighted avg 0.6482 0.6505 0.6422 23619

Pentru SVM:

precision recall f1-score support

Apple 0.9011 0.9774 0.9377 2525
 Apricot 0.9939 1.0000 0.9970 164
 Avocado 0.9035 1.0000 0.9493 309
 Banana 0.6423 0.8347 0.7260 484
 Beetroot 0.8976 0.7600 0.8231 150
 Blueberry 0.9935 1.0000 0.9968 154
 Cabbage 0.9388 0.9787 0.9583 47
 Cactus 0.9855 0.8193 0.8947 166
 Cantaloupe 0.9909 0.9970 0.9939 328
 Carambola 0.9750 0.9398 0.9571 166
 Carrot 1.0000 1.0000 1.0000 50
 Cauliflower 0.9331 0.9530 0.9429 234
 Cherry 0.9665 0.9556 0.9610 1148
 Chestnut 0.9481 0.8366 0.8889 153
 Clementine 1.0000 1.0000 1.0000 166

Cocos 0.9866 0.8855 0.9333 166
Corn 0.8708 0.5987 0.7096 304
Cucumber 0.9713 0.8921 0.9300 417
Dates 0.9934 0.9096 0.9497 166
Eggplant 0.9029 0.7881 0.8416 236
Fig 1.0000 0.9957 0.9979 234
Ginger 0.9103 0.7172 0.8023 99
Granadilla 1.0000 1.0000 1.0000 166
Grape 0.9617 0.9860 0.9737 1146
Grapefruit 1.0000 1.0000 1.0000 330
Guava 1.0000 1.0000 1.0000 166
Hazelnut 0.9474 0.9172 0.9320 157
Huckleberry 1.0000 1.0000 1.0000 166
Kaki 1.0000 1.0000 1.0000 166
Kiwi 1.0000 1.0000 1.0000 156
Kohlrabi 1.0000 0.9682 0.9838 157
Kumquats 1.0000 1.0000 1.0000 166
Lemon 1.0000 1.0000 1.0000 330
Limes 0.9708 1.0000 0.9852 166
Lychee 1.0000 0.9699 0.9847 166
Mandarine 1.0000 0.9337 0.9657 166
Mango 0.9965 0.9351 0.9648 308
Mangostan 0.9515 0.9608 0.9561 102
Maracuja 0.9345 0.9458 0.9401 166
Melon 0.9959 0.9878 0.9918 246
Mulberry 1.0000 0.9939 0.9969 164
Nectarine 0.8586 0.7870 0.8213 324
Nut 0.9915 0.8838 0.9346 396
Onion 0.8756 0.8736 0.8746 451
Orange 0.9302 1.0000 0.9639 160
Papaya 1.0000 1.0000 1.0000 164
Passion 1.0000 1.0000 1.0000 166
Peach 0.9450 0.9878 0.9659 574
Pear 0.9091 0.8802 0.8944 1761
Pepino 0.9920 0.7470 0.8522 166
Pepper 0.8894 0.9540 0.9206 826
Physalis 0.8814 0.9970 0.9356 328

Pineapple	0.9792	1.0000	0.9895	329
Pitahaya	0.9708	1.0000	0.9852	166
Plum	0.9241	0.9581	0.9408	597
Pomegranate	0.9671	0.8963	0.9304	164
Pomelo	1.0000	1.0000	1.0000	153
Potato	0.9564	0.9118	0.9336	601
Quince	1.0000	1.0000	1.0000	166
Rambutan	0.9939	1.0000	0.9970	164
Raspberry	1.0000	0.9940	0.9970	166
Redcurrant	1.0000	0.9939	0.9969	164
Salak	0.9759	1.0000	0.9878	162
Strawberry	0.9576	0.8805	0.9174	410
Tamarillo	0.9881	1.0000	0.9940	166
Tangelo	0.9651	1.0000	0.9822	166
Tomato	0.9761	0.9555	0.9657	1707
Walnut	0.9765	1.0000	0.9881	249
Watermelon	0.9931	0.9108	0.9502	157
Zucchini	0.9639	1.0000	0.9816	160

accuracy 0.9417 23619

macro avg 0.9618 0.9436 0.9509 23619

weighted avg 0.9442 0.9417 0.9415 23619

Pentru Random Forest:

precision recall f1-score support

Apple 0.9011 0.9774 0.9377 2525

Apricot 0.9939 1.0000 0.9970 164

Avocado 0.9035 1.0000 0.9493 309

Banana 0.6423 0.8347 0.7260 484

Beetroot 0.8976 0.7600 0.8231 150

Blueberry 0.9935 1.0000 0.9968 154

Cabbage 0.9388 0.9787 0.9583 47

Cactus 0.9855 0.8193 0.8947 166

Cantaloupe 0.9909 0.9970 0.9939 328

Carambola 0.9750 0.9398 0.9571 166

Carrot 1.0000 1.0000 1.0000 50

Cauliflower 0.9331 0.9530 0.9429 234

Cherry 0.9665 0.9556 0.9610 1148
Chestnut 0.9481 0.8366 0.8889 153
Clementine 1.0000 1.0000 1.0000 166
Cocos 0.9866 0.8855 0.9333 166
Corn 0.8708 0.5987 0.7096 304
Cucumber 0.9713 0.8921 0.9300 417
Dates 0.9934 0.9096 0.9497 166
Eggplant 0.9029 0.7881 0.8416 236
Fig 1.0000 0.9957 0.9979 234
Ginger 0.9103 0.7172 0.8023 99
Granadilla 1.0000 1.0000 1.0000 166
Grape 0.9617 0.9860 0.9737 1146
Grapefruit 1.0000 1.0000 1.0000 330
Guava 1.0000 1.0000 1.0000 166
Hazelnut 0.9474 0.9172 0.9320 157
Huckleberry 1.0000 1.0000 1.0000 166
Kaki 1.0000 1.0000 1.0000 166
Kiwi 1.0000 1.0000 1.0000 156
Kohlrabi 1.0000 0.9682 0.9838 157
Kumquats 1.0000 1.0000 1.0000 166
Lemon 1.0000 1.0000 1.0000 330
Limes 0.9708 1.0000 0.9852 166
Lychee 1.0000 0.9699 0.9847 166
Mandarine 1.0000 0.9337 0.9657 166
Mango 0.9965 0.9351 0.9648 308
Mangostan 0.9515 0.9608 0.9561 102
Maracuja 0.9345 0.9458 0.9401 166
Melon 0.9959 0.9878 0.9918 246
Mulberry 1.0000 0.9939 0.9969 164
Nectarine 0.8586 0.7870 0.8213 324
Nut 0.9915 0.8838 0.9346 396
Onion 0.8756 0.8736 0.8746 451
Orange 0.9302 1.0000 0.9639 160
Papaya 1.0000 1.0000 1.0000 164
Passion 1.0000 1.0000 1.0000 166
Peach 0.9450 0.9878 0.9659 574
Pear 0.9091 0.8802 0.8944 1761

Pepino 0.9920 0.7470 0.8522 166
 Pepper 0.8894 0.9540 0.9206 826
 Physalis 0.8814 0.9970 0.9356 328
 Pineapple 0.9792 1.0000 0.9895 329
 Pitahaya 0.9708 1.0000 0.9852 166
 Plum 0.9241 0.9581 0.9408 597
 Pomegranate 0.9671 0.8963 0.9304 164
 Pomelo 1.0000 1.0000 1.0000 153
 Potato 0.9564 0.9118 0.9336 601
 Quince 1.0000 1.0000 1.0000 166
 Rambutan 0.9939 1.0000 0.9970 164
 Raspberry 1.0000 0.9940 0.9970 166
 Redcurrant 1.0000 0.9939 0.9969 164
 Salak 0.9759 1.0000 0.9878 162
 Strawberry 0.9576 0.8805 0.9174 410
 Tamarillo 0.9881 1.0000 0.9940 166
 Tangelo 0.9651 1.0000 0.9822 166
 Tomato 0.9761 0.9555 0.9657 1707
 Walnut 0.9765 1.0000 0.9881 249
 Watermelon 0.9931 0.9108 0.9502 157
 Zucchini 0.9639 1.0000 0.9816 160

accuracy 0.9417 23619
 macro avg 0.9618 0.9436 0.9509 23619
 weighted avg 0.9442 0.9417 0.9415 23619

Pentru xgboost:

precision recall f1-score support
 0 0.7333 0.9723 0.8360 2525
 1 0.6614 0.5122 0.5773 164
 2 0.8812 0.9126 0.8967 309
 3 0.7875 0.7273 0.7562 484
 4 0.7128 0.4467 0.5492 150
 5 1.0000 0.7338 0.8464 154
 6 0.7143 0.9574 0.8182 47
 7 0.7582 0.8313 0.7931 166
 8 1.0000 0.9756 0.9877 328

9 0.8288 0.7289 0.7756 166
10 0.7833 0.9400 0.8545 50
11 0.9831 0.7479 0.8495 234
12 0.9179 0.9155 0.9167 1148
13 0.7890 0.5621 0.6565 153
14 0.9688 0.9337 0.9509 166
15 0.9392 0.8373 0.8854 166
16 0.7310 0.4737 0.5749 304
17 0.9531 0.7794 0.8575 417
18 0.9875 0.9518 0.9693 166
19 0.8786 0.6441 0.7433 236
20 0.9936 0.6667 0.7980 234
21 0.8085 0.3838 0.5205 99
22 0.9702 0.9819 0.9760 166
23 0.9184 0.9721 0.9445 1146
24 1.0000 0.9909 0.9954 330
25 1.0000 1.0000 1.0000 166
26 0.8690 0.9299 0.8985 157
27 1.0000 1.0000 1.0000 166
28 0.8557 1.0000 0.9222 166
29 0.9500 0.8526 0.8986 156
30 0.7794 0.3376 0.4711 157
31 0.9624 0.7711 0.8562 166
32 0.9414 0.8758 0.9074 330
33 0.8314 0.8614 0.8462 166
34 0.9931 0.8675 0.9260 166
35 1.0000 0.8614 0.9256 166
36 0.9043 0.6136 0.7311 308
37 0.9863 0.7059 0.8229 102
38 1.0000 0.7771 0.8746 166
39 0.9205 0.9878 0.9529 246
40 1.0000 0.9146 0.9554 164
41 0.9205 0.5000 0.6480 324
42 0.8393 0.7652 0.8005 396
43 0.7495 0.8293 0.7874 451
44 0.9353 0.9938 0.9636 160
45 0.9509 0.9451 0.9480 164

46 0.9811 0.9398 0.9600 166
47 0.8317 0.7317 0.7785 574
48 0.7046 0.7626 0.7325 1761
49 0.6919 0.7711 0.7293 166
50 0.9291 0.8414 0.8831 826
51 0.8511 0.9756 0.9091 328
52 0.7718 0.9970 0.8700 329
53 0.9200 0.6928 0.7904 166
54 0.8382 0.9112 0.8732 597
55 0.8418 0.8110 0.8261 164
56 1.0000 0.9477 0.9732 153
57 0.7256 0.7038 0.7145 601
58 0.9595 1.0000 0.9794 166
59 0.8256 0.8659 0.8452 164
60 1.0000 0.9940 0.9970 166
61 0.9669 0.8902 0.9270 164
62 0.8265 1.0000 0.9050 162
63 0.9344 0.8341 0.8814 410
64 0.9881 1.0000 0.9940 166
65 0.8728 0.9096 0.8909 166
66 0.8947 0.9602 0.9263 1707
67 0.8526 0.9759 0.9101 249
68 0.8515 0.5478 0.6667 157
69 1.0000 0.8375 0.9116 160

accuracy 0.8515 23619

macro avg 0.8878 0.8267 0.8477 23619

weighted avg 0.8591 0.8515 0.8478 23619

Algorithmi disting foarte bine features bazate pe contur, respectiv pe componente principale. Modelele reusesc sa invete fructe cu forme neobisnuite si culori neobisnuite, chiar daca sunt putine imagini in setul de date.

0.9 Prediction, Recall, F1-score MNIST

Pentru Random Forest:

precision recall f1-score support

0	0.7992	0.8480	0.8229	1000
1	0.9867	0.9670	0.9768	1000
2	0.7923	0.7860	0.7892	1000
3	0.8783	0.8950	0.8866	1000
4	0.7768	0.8320	0.8035	1000
5	0.9173	0.8990	0.9081	1000
6	0.7033	0.5880	0.6405	1000
7	0.8846	0.8740	0.8793	1000
8	0.9420	0.9740	0.9577	1000
9	0.8912	0.9260	0.9083	1000

accuracy 0.8589 10000

macro avg 0.8572 0.8589 0.8573 10000

weighted avg 0.8572 0.8589 0.8573 10000

Pentru xgboost:

precision recall f1-score support

0	0.8062	0.8570	0.8308	1000
1	0.9797	0.9650	0.9723	1000
2	0.8043	0.7850	0.7945	1000
3	0.8804	0.8910	0.8857	1000
4	0.7950	0.8340	0.8141	1000
5	0.9265	0.9080	0.9172	1000
6	0.7055	0.6300	0.6656	1000
7	0.9012	0.8940	0.8976	1000
8	0.9578	0.9750	0.9663	1000
9	0.9050	0.9340	0.9193	1000

accuracy 0.8673 10000

macro avg 0.8662 0.8673 0.8663 10000

weighted avg 0.8662 0.8673 0.8663 10000

Pentru Logistic Regression:

precision recall f1-score support

0	0.7755	0.8120	0.7934	1000
1	0.9504	0.9580	0.9542	1000
2	0.7543	0.6630	0.7057	1000

```
3 0.7953 0.8510 0.8222 1000
4 0.7059 0.7800 0.7411 1000
5 0.8871 0.8880 0.8876 1000
6 0.5562 0.4850 0.5182 1000
7 0.8659 0.8590 0.8624 1000
8 0.9336 0.9420 0.9378 1000
9 0.8928 0.9080 0.9003 1000
```

```
accuracy 0.8146 10000
macro avg 0.8117 0.8146 0.8123 10000
weighted avg 0.8117 0.8146 0.8123 10000
```

Pentru SVM:

```
precision recall f1-score support
0 0.8195 0.8400 0.8296 1000
1 0.9898 0.9740 0.9819 1000
2 0.8302 0.8070 0.8185 1000
3 0.8838 0.9050 0.8943 1000
4 0.8164 0.8450 0.8305 1000
5 0.9556 0.9260 0.9406 1000
6 0.7232 0.6870 0.7046 1000
7 0.9050 0.9340 0.9193 1000
8 0.9702 0.9780 0.9741 1000
9 0.9421 0.9430 0.9425 1000
```

```
accuracy 0.8839 10000
macro avg 0.8836 0.8839 0.8836 10000
weighted avg 0.8836 0.8839 0.8836 10000
```

Toate modelele, indiferent de felul lor, reusesc sa invete mai bine anumite clase: clasele 1, 3, 5, 8 si 9. Fiind grayscale, acesta ingreuneaza procesul modelului de a invata. De asemenea, bazat si pe vizualizarea imaginilor folosind PCA, unele clase pot fi asemanatoare estetic, diferenta facandu-se la hu moments. De exemplu, coat si pullover seamana foarte mult atat la contur, cat si la pca, modelele deci pot sa le confunde.




Abbildung 34: Confusion Matrix Logistic Regression Fruits




Abbildung 35: Confusion Matrix Logistic Regression MNIST




Abbildung 36: Confusion Matrix Random Forest Fruits




Abbildung 37: Confusion Matrix Random Forest MNIST




Abbildung 38: Confusion Matrix SVC Fruits




Abbildung 39: Confusion Matrix SVC MNIST




Abbildung 40: Confusion Matrix xgboost Fruits




Abbildung 41: Confusion Matrix xgboost MNIST